Étude empirique de l'avantage à domicile en Premier League

Peut-on mettre en évidence, à partir des données, une tendance significative en faveur des équipes à domicile ?

Réalisé par :

Salma ALAOUI MRANI

Sommaire

I Introduction **3**

II Choix du thème et des données **3**

III Nettoyage et préparation des données **4**

IV Analyse exploratoire des données **5**

IV.1 Distribution des données 5
IV.2 Évolution du taux de victoire dans le temps 6
IV.3 Effet du Covid-19 6
IV.4 Le niveau des équipes dans l'avantage à domicile 7
IV.5 Corrélation des variables 8
IV.6 Evolution des buts à domicile vs extérieur 9
IV.7 Le taux de victoire des Big Six 10

V Conclusion **11**

Table des figures

1 Distribution de l'échantillon (1993-2023) 5
2 Evolution du taux de victoire à domicile par saison 6
3 Evolution du taux de victoire à domicile par saison 7
4 Taux de victoire à domicile selon le niveau relatif des équipes 8
5 Matrice de corrélation des variables numériques 9
6 Evolution des buts à domicile vs extérieur par saison 10
7 Big Six - Taux de victoire à domicile vs à l'extérieur 11

I Introduction

Le football professionnel, en particulier la Premier League, est souvent associé à l'idée d'un avantage à domicile. Il est généralement admis que jouer sur son terrain augmente les chances de victoire, notamment grâce au soutien du public, à une meilleure connaissance de l'environnement ou encore à certains effets psychologiques.

Cependant, cette idée mérite d'être nuancée à la lumière des évolutions récentes du football. La professionnalisation accrue du sport, l'amélioration des conditions de déplacement ainsi que l'introduction de technologies comme l'assistance vidéo à l'arbitrage peuvent contribuer à réduire cet avantage. Surtout, la période du Covid-19, durant laquelle les matchs se sont déroulés sans spectateurs, constitue un contexte unique pour observer l'impact réel de l'absence de public.

Par ailleurs, il est nécessaire de tenir compte du niveau relatif des équipes. Une équipe plus performante a naturellement plus de chances de gagner, indépendamment du lieu du match. Il devient donc essentiel de distinguer ce qui relève réellement du facteur domicile de ce qui s'explique par les différences de niveau.

Dans ce contexte, la problématique suivante se pose : Dans quelle mesure l'avantage du terrain influence-t-il réellement les résultats en Premier League, et persiste-t-il lorsque l'on contrôle le niveau relatif des équipes ?

Afin d'y répondre, ce travail s'appuie sur une analyse de données couvrant plusieurs saisons de Premier League, en combinant une approche descriptive et une analyse statistique permettant d'évaluer l'influence du facteur domicile.

II Choix du thème et des données

Le choix de ce projet s'inscrit dans une volonté d'analyser un phénomène largement reconnu, mais rarement questionné de manière quantitative : l'avantage à domicile dans le football.

Le football constitue un terrain d'étude particulièrement pertinent, car il combine une forte disponibilité de données, une lecture intuitive des résultats et une application concrète à un contexte réel. Ces caractéristiques en font un support idéal pour une analyse statistique accessible tout en restant rigoureuse.

Dans ce cadre, la Premier League a été retenue en raison de plusieurs atouts. Il s'agit d'un championnat à la fois très compétitif, médiatisé, et disposant d'un historique de données riche et continu. Cette profondeur temporelle permet d'étudier l'évolution des tendances sur le long terme, tout en intégrant des périodes spécifiques comme celle du Covid-19.

Le jeu de données utilisé couvre les matchs de Premier League sur la période 1993 à 2023. Il inclut plusieurs variables essentielles à l'analyse, notamment :

— le résultat du match (FTR)

— le nombre de buts marqués par chaque équipe (HomeGoals, AwayGoals)
— la saison
— ainsi qu'un indicateur de différence de niveau entre équipes (StrengthDiff), utilisé comme proxy du niveau relatif

Ces variables permettent d'étudier à la fois les résultats, la performance offensive, ainsi que l'influence du niveau des équipes sur l'issue des matchs.

Enfin, les données ont été extraites d'une source ouverte (type Kaggle), garantissant leur accessibilité et leur reproductibilité.

III Nettoyage et préparation des données

Avant de procéder à l'analyse, un travail de nettoyage et de préparation des données a été réalisé afin d'obtenir un jeu de données cohérent, lisible et exploitable. Cette étape est essentielle pour garantir la cohérence et la fiabilité des analyses.

Dans un premier temps, le dataset brut a été importé puis trié de manière chronologique selon la saison, la semaine de jeu et la date du match. Cette organisation était nécessaire pour construire par la suite un indicateur dynamique du niveau des équipes. Les noms de certaines colonnes ont également été harmonisés afin d'assurer une structure claire et uniforme, notamment pour les variables relatives aux équipes et aux buts marqués.

Une vérification des valeurs manquantes a également été effectuée au début du traitement. Même si le dataset ne présentait pas de problème majeur, cette étape permettait de contrôler la qualité générale des données avant d'engager les transformations.

Au-delà du nettoyage, plusieurs variables ont ensuite été construites pour enrichir l'analyse :

— *HomeWin* : variable binaire prenant la valeur 1 lorsque l'équipe à domicile remporte le match, et 0 sinon ;
— *GoalDiff* : différence entre les buts marqués par l'équipe à domicile et ceux marqués par l'équipe à l'extérieur ;
— *TotalGoals* : nombre total de buts inscrits au cours du match ;
— *StrengthDiff* : écart de niveau estimé entre les deux équipes.

La construction de la variable *StrengthDiff* constitue un point central de la préparation des données. Pour cela, un tableau intermédiaire a d'abord été créé au niveau des équipes, en attribuant à chaque match un nombre de points selon le résultat obtenu (3 points pour une victoire, 1 pour un match nul, 0 pour une défaite). À partir de cette base, un indicateur de force a été calculé pour chaque équipe comme la moyenne glissante des points obtenus lors des cinq matchs précédents. Cette méthode permet d'obtenir une mesure évolutive du niveau de forme des équipes au fil de la saison. La variable *StrengthDiff* correspond ensuite à la différence entre la force estimée de l'équipe à domicile et celle de l'équipe à l'extérieur.

Enfin, des variables contextuelles ont été ajoutées afin de prendre en compte l'effet de la période sanitaire :

— *Covid* : variable binaire identifiant les saisons 2020 et 2021, marquées par des matchs joués sans ou avec peu de public. À partir de cette variable, les matchs ont été regroupés en différentes périodes (avant, pendant et après Covid)

L'ensemble de ces transformations a permis de passer d'un jeu de données brut à un dataset structuré, enrichi et directement exploitable pour l'analyse descriptive et statistique.

IV Analyse exploratoire des données

IV.1 Distribution des données

La première étape de notre analyse consiste à examiner la distribution de notre variable cible, HomeWin, afin de vérifier si nos données présentent un déséquilibre initial.

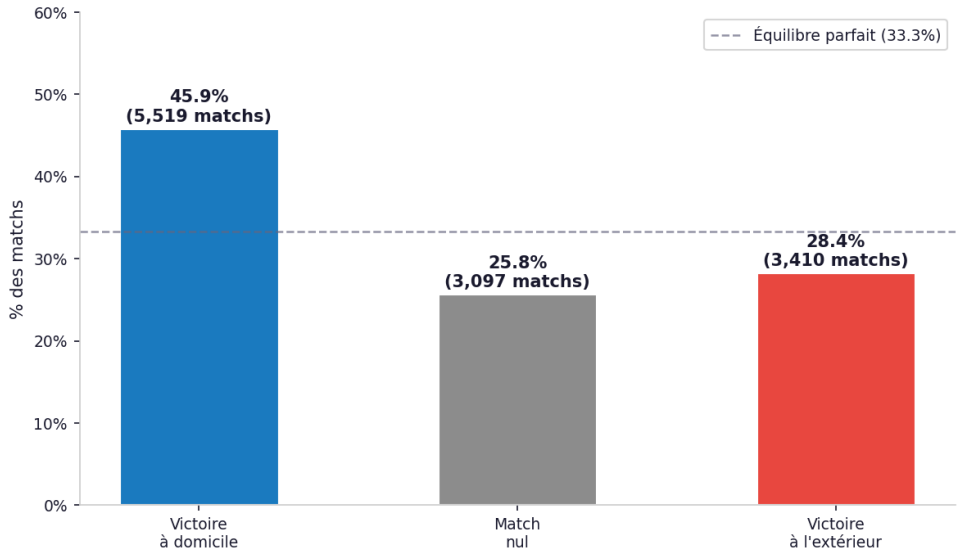


FIGURE 1 – Distribution de l'échantillon (1993-2023)

Sur l'ensemble des 12 026 matchs couvrant les saisons 1993 à 2023, les victoires à domicile représentent 45,9% des résultats, contre 28,4% pour les victoires à l'extérieur et 25,8% de matchs nuls. Si le fait de jouer à domicile n'exerçait aucune influence sur l'issue du match, on s'attendrait à une répartition équilibrée autour de 33% pour chacune des trois issues. L'écart observé de 12 points par rapport à cet équilibre théorique constitue une première indication forte d'un avantage domicile structurel, et c'est précisément ce phénomène que notre analyse cherche à comprendre et à expliquer.

IV.2 Évolution du taux de victoire dans le temps

Après avoir établi l'existence d'un déséquilibre global, nous nous sommes interrogées sur sa stabilité dans le temps.

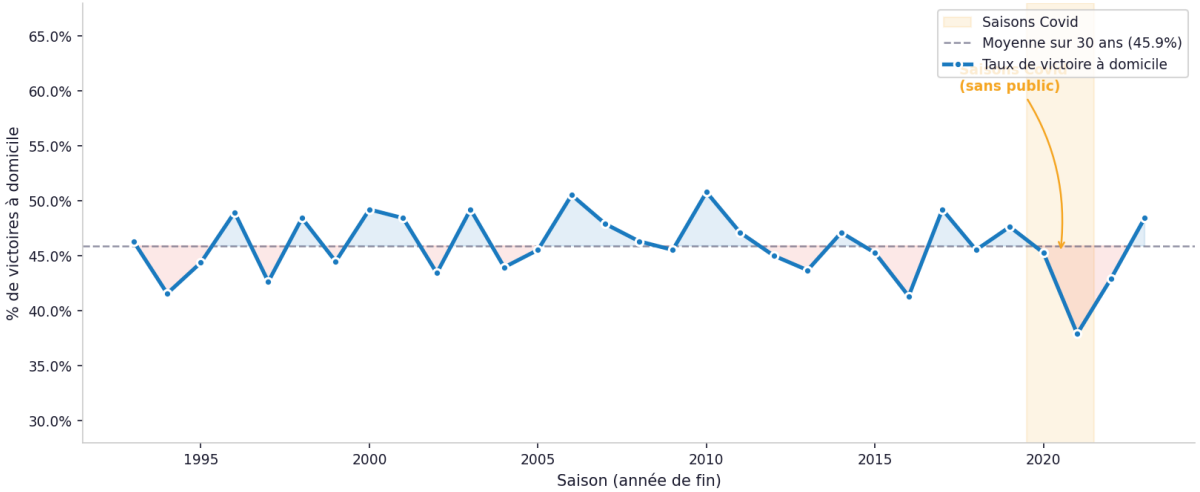


FIGURE 2 – Evolution du taux de victoire à domicile par saison

Le taux de victoire à domicile oscille autour de 43% à 47% sur l'ensemble de la période, sans tendance haussière ou baissière marquée, ce qui confirme que l'avantage domicile est un phénomène stable et persistant sur trois décennies de Premier League.

La courbe présente un profil en dents de scie d'une saison à l'autre, reflet de l'équilibre variable du championnat. Certaines saisons voient une équipe dominer si nettement qu'elle performe aussi bien à l'extérieur qu'à domicile, ce qui fait mécaniquement baisser le taux global. L'absence de pic notable en 2014-2015 illustre bien ce phénomène : cette saison particulièrement compétitive dans le milieu de tableau a vu les équipes visiteuses performer de façon atypique.

L'élément le plus saillant de ce graphique est la chute brutale observée lors des saisons 2020 et 2021, où le taux de victoire domicile atteint son niveau le plus bas en 30 ans, à environ 38%. Ces saisons correspondent aux périodes jouées à huis clos en raison de la pandémie de Covid-19, ce qui constitue une première piste d'explication que nous allons approfondir.

IV.3 Effet du Covid-19

Pour isoler l'effet de l'absence de public, nous avons comparé trois périodes distinctes : avant Covid de 1993 à 2019, pendant Covid en 2020 et 2021, et après Covid de 2022 à 2023.

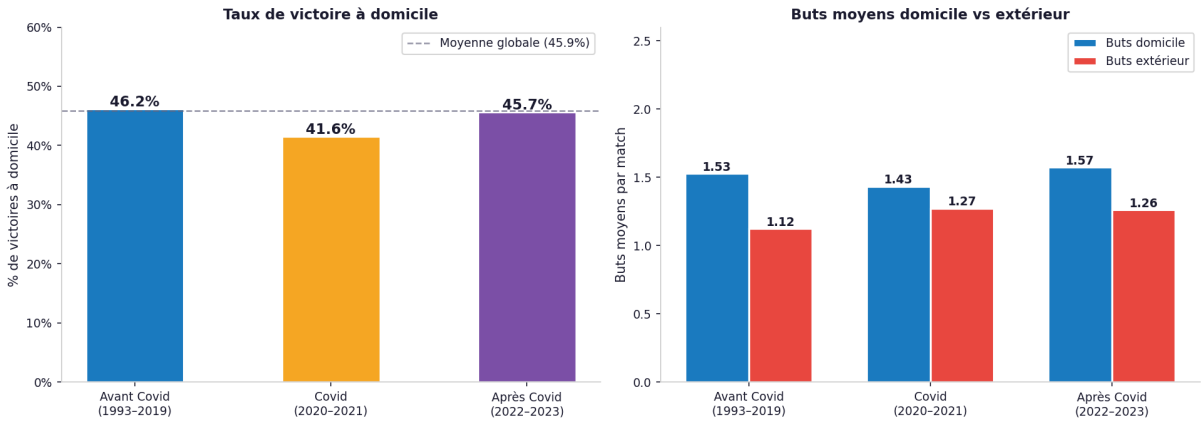


FIGURE 3 – Evolution du taux de victoire à domicile par saison

Les résultats sont particulièrement révélateurs. Le taux de victoire à domicile passe de 46,2% avant le Covid à 41,6% pendant, soit une chute de près de 5 points, avant de remonter à 45,7% dès le retour du public. Ce retour quasi immédiat au niveau d'avant Covid est l'argument le plus convaincant en faveur d'un lien causal entre la présence des supporters et l'avantage domicile.

L'analyse des buts vient renforcer cette lecture. Pendant le Covid, les buts extérieurs augmentent sensiblement, passant de 1,12 à 1,27 en moyenne par match, tandis que les buts domicile diminuent de 1,53 à 1,43. Les deux indicateurs pointent dans la même direction : sans public, quelque chose change fondamentalement dans le rapport domicile-extérieur. Le public ne se contente pas d'influencer les décisions arbitrales, il semble agir sur le jeu lui-même, vraisemblablement via la pression psychologique exercée sur les joueurs adverses et le soutien apporté à l'équipe locale.

IV.4 Le niveau des équipes dans l'avantage à domicile

L'analyse précédente confirme l'existence d'un avantage domicile, mais une question essentielle demeure : cet avantage persiste-t-il même lorsque l'équipe visiteuse est objectivement supérieure ? C'est l'objet de ce quatrième graphique, qui croise notre variable StrengthDiff, mesurant la différence de niveau entre les deux équipes via une moyenne glissante sur les 5 derniers matchs, avec le taux de victoire à domicile.

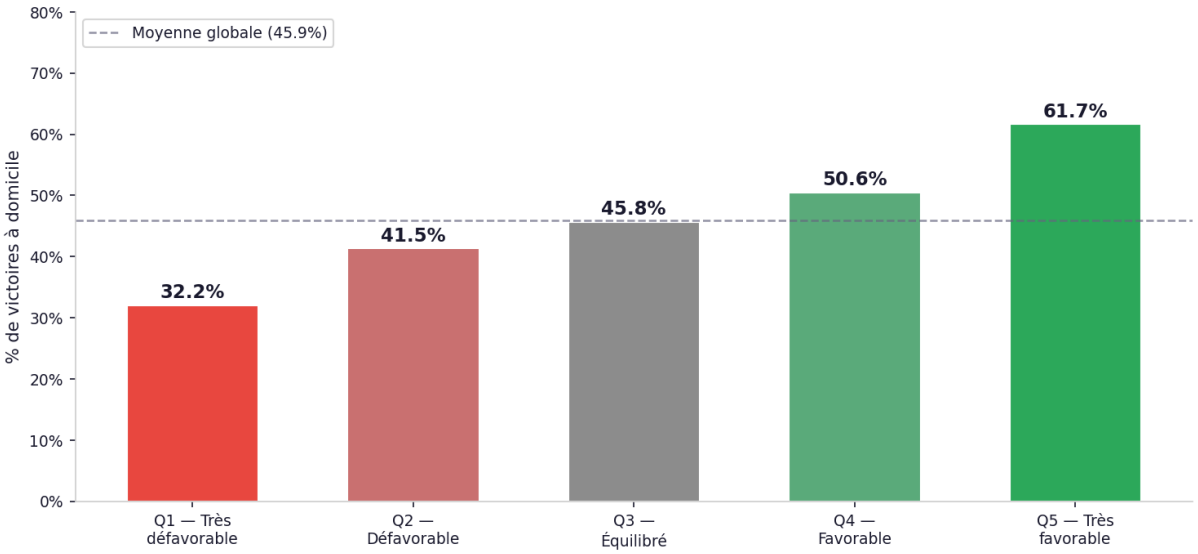


FIGURE 4 – Taux de victoire à domicile selon le niveau relatif des équipes

Nous avons découpé StrengthDiff en cinq quintiles, du contexte le plus défavorable au domicile en Q1 au plus favorable en Q5. Sans surprise, le taux de victoire augmente avec le niveau relatif de l'équipe, passant de 32,2% en Q1 à 61,7% en Q5. Mais ce qui est analytiquement le plus intéressant, c'est précisément le quintile Q1 : même lorsque l'équipe à domicile est très inférieure sur le papier, elle remporte près d'un match sur trois. Ce résultat suggère que l'avantage domicile s'exprime indépendamment du niveau relatif des équipes, il existe une composante résiduelle qui ne s'explique pas par la force des équipes en présence.

IV.5 Corrélation des variables

La heatmap des corrélations offre une vue synthétique des relations linéaires entre l'ensemble de nos variables numériques. Une valeur proche de 1 indique que deux variables évoluent dans le même sens, proche de -1 qu'elles évoluent en sens inverse, et proche de 0 qu'il n'existe pas de relation linéaire entre elles.

Plusieurs corrélations retiennent l'attention. La plus forte de la matrice est celle entre GoalDiff et HomeWin à 0,78, logique, puisque marquer plus que l'adversaire revient mécaniquement à gagner. Dans la même veine, HomeGoals et GoalDiff corrèlent à 0,77, et AwayGoals et GoalDiff à -0,68 : plus l'équipe visiteuse marque, plus elle fait baisser la différence de buts en faveur du domicile. Ces fortes corrélations sont en partie des artefacts de construction, elles valident la cohérence de nos variables sans apporter d'information nouvelle sur l'avantage domicile en soi.

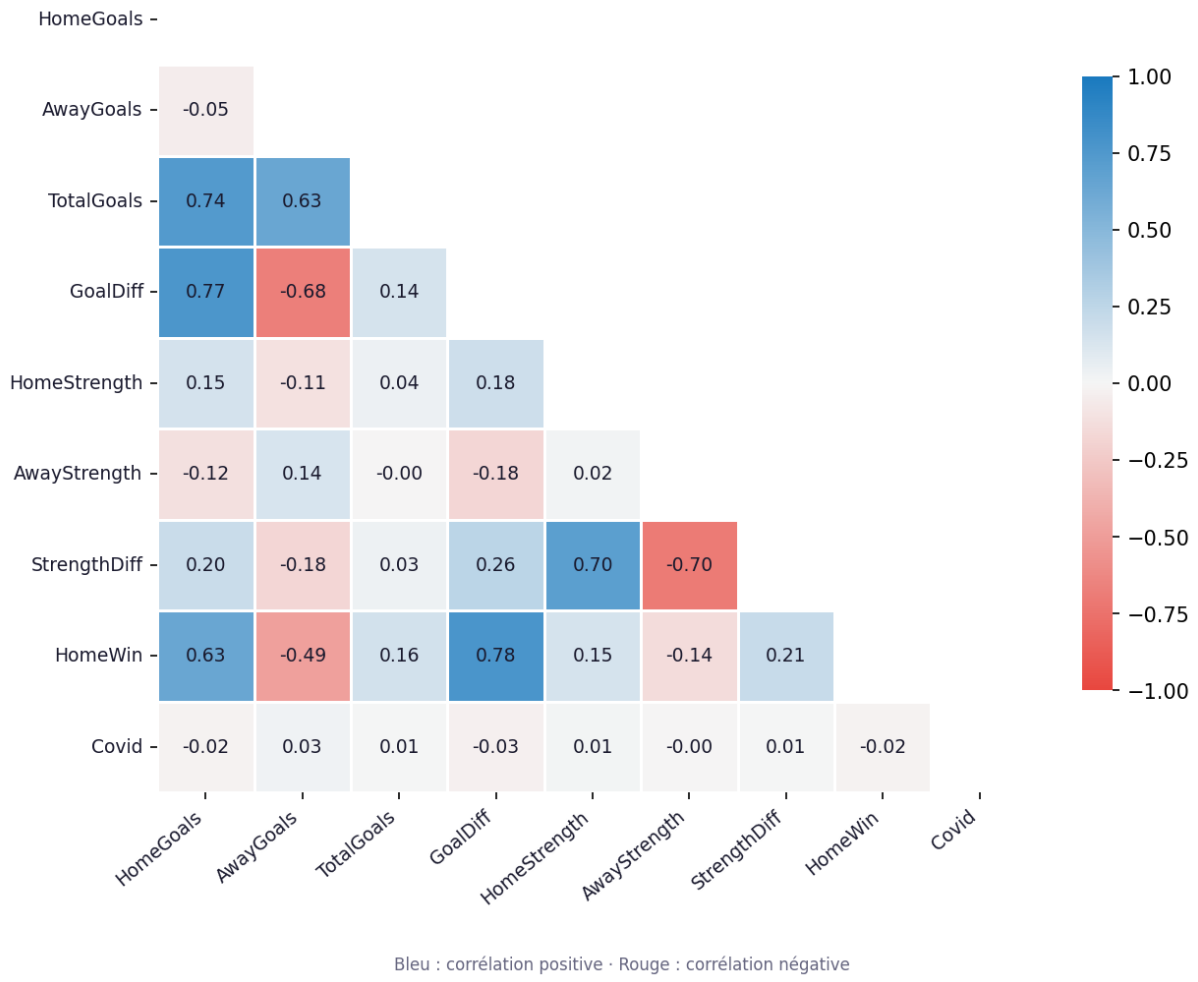


FIGURE 5 – Matrice de corrélation des variables numériques

La corrélation analytiquement la plus intéressante est celle entre StrengthDiff et HomeWin à 0,21 : positive mais modérée, elle confirme que le niveau relatif des équipes influence le résultat, sans pour autant l'expliquer entièrement. Il subsiste donc une part structurelle inexpliquée, c'est précisément là que se loge l'avantage domicile.

On notera enfin que Covid présente des corrélations proches de 0 avec toutes les variables. Ce résultat n'est pas surprenant : avec seulement deux saisons sur trente concernées, l'effet Covid est trop localisé pour apparaître dans une corrélation calculée sur l'ensemble du dataset. C'est précisément pour cette raison que nous lui avons consacré une analyse à part, qui révèle toute sa force.

IV.6 Evolution des buts à domicile vs extérieur

Le graphique suivant complète l'analyse temporelle en examinant non plus les résultats mais les buts.

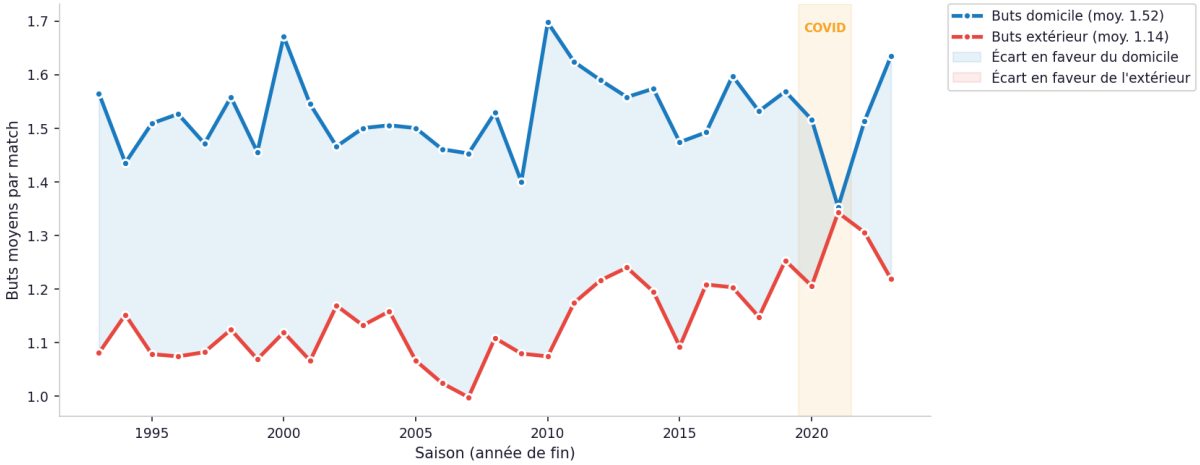


FIGURE 6 – Evolution des buts à domicile vs extérieur par saison

Sur l'ensemble de la période, la courbe des buts domicile est systématiquement au-dessus de celle des buts extérieurs, avec une moyenne de 1,52 contre 1,14, soit un écart de 0,38 but par match maintenu sur trois décennies.

On observe par ailleurs une tendance de fond intéressante : les buts extérieurs présentent une légère hausse depuis les années 2010, suggérant que le football moderne tend progressivement à réduire l'avantage domicile. Cette évolution peut s'expliquer par plusieurs facteurs : la sophistication tactique croissante qui favorise le jeu en transition, l'homogénéisation du niveau entre clubs grâce aux investissements massifs, ou encore l'introduction du VAR en 2019 qui a réduit certains avantages informels liés à la pression du public sur les décisions arbitrales.

Pendant les saisons Covid, la zone entre les deux courbes se rétrécit nettement, les buts domicile chutent à 1,43 tandis que les buts extérieurs remontent à 1,27. Ce resserrement confirme ce qu'on observait sur le graphique 3 : le public influence le jeu dans son ensemble, pas uniquement le score final.

IV.7 Le taux de victoire des Big Six

Pour clore notre analyse exploratoire, nous avons vérifié que l'avantage domicile n'est pas un phénomène limité aux équipes modestes ou aux matchs déséquilibrés.

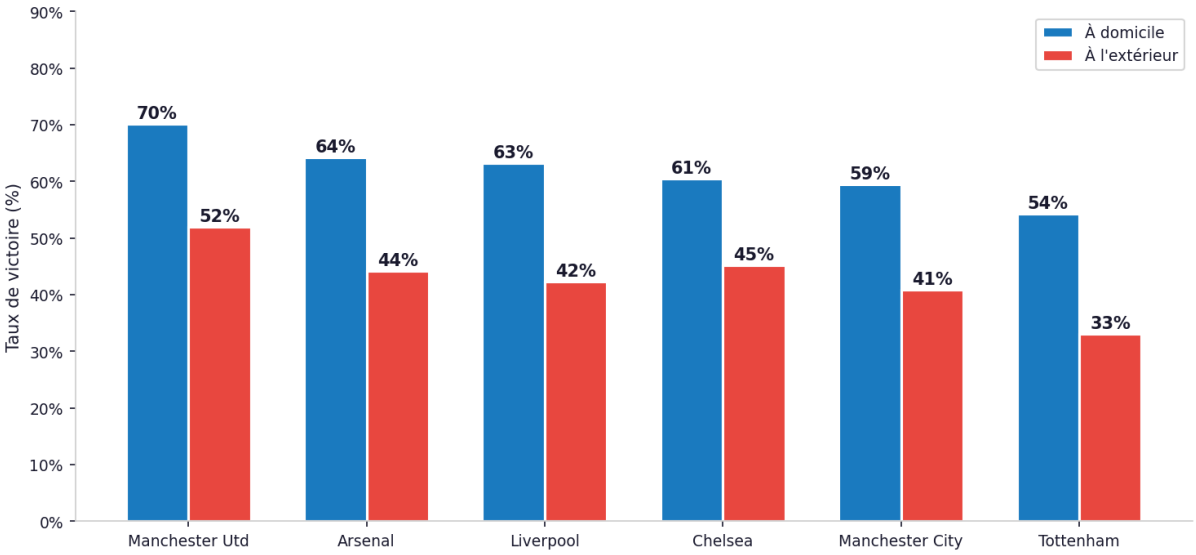


FIGURE 7 – Big Six - Taux de victoire à domicile vs à l'extérieur

Le graphique du Big Six est particulièrement éloquent : pour chacun des six plus grands clubs de Premier League sans exception, le taux de victoire à domicile est systématiquement supérieur au taux à l'extérieur.

Manchester United présente le taux domicile le plus élevé avec 70%, contre 52% à l'extérieur. Tottenham affiche l'écart le plus marqué en valeur relative : 54% à domicile contre seulement 33% à l'extérieur. Même Manchester City, pourtant la formation la plus dominante de la décennie 2010-2020, enregistre 59% à domicile contre 41% à l'extérieur. La domination financière et sportive ne suffit pas à effacer l'avantage domicile.

V Conclusion

Notre analyse exploratoire sur 30 saisons de Premier League nous permet de répondre clairement à notre question de départ : jouer à domicile confère un avantage réel, structurel et universel.

Trois résultats convergent vers cette conclusion. D'abord, les équipes à domicile gagnent 45,9% des matchs sur l'ensemble de la période, soit 12 points au-dessus de l'équilibre théorique. Ensuite, cet avantage persiste même lorsque l'équipe visiteuse est objectivement plus forte, le quintile Q1 le démontre clairement avec un taux de victoire domicile de 32,2% dans les contextes les plus défavorables. Enfin, l'expérience naturelle du Covid constitue l'argument le plus convaincant : sans public, l'avantage domicile chute de 5 points et remonte dès le retour des supporters.

Il convient cependant de souligner certaines limites méthodologiques. Notre variable StrengthDiff, construite à partir d'une moyenne glissante sur les 5 derniers matchs, constitue une approximation du niveau réel des équipes. Elle ne capture pas certains facteurs difficilement quantifiables, comme la fatigue des joueurs liée aux déplacements, les équipes

visiteuses parcourent parfois plusieurs centaines de kilomètres avant un match, ce qui peut affecter leurs performances sans que cela soit reflété dans notre mesure de force. De même, les blessures de joueurs clés, les conditions climatiques, ou encore l'effet psychologique d'une série de défaites consécutives sont autant de facteurs qui influencent le résultat sans être capturés par notre modèle.

Pour aller plus loin, une régression logistique avec HomeWin comme variable dépendante et StrengthDiff, Covid et `Season_End_Year` comme variables explicatives permettrait de quantifier précisément la contribution de chaque facteur et de tester leur significativité statistique. Elle confirmerait ou infirmerait nos résultats exploratoires sur une base formelle, et ouvrirait la voie à une modélisation prédictive de l'issue des matchs.